


CURS 8 - SERII DE TIMP


Valorile discrete înregistrate în timp, obținute ca rezultat al observațiilor făcute asupra diferitelor fenomene, sunt înregistrate sub forma seriilor cronologice, denumite și serii de timp sau serii dinamice. O definiție foarte succintă a unei serii cronologice ar putea fi o colecție de valori înregistrate secvențial în timp.

Studiul seriilor de timp, în diferite domenii de activitate, precede înregistrările documentare ale istoriei. Economii secolelor trecute au făcut de multe ori referire la metode de analiză a seriilor de timp preluate din domeniul astronomiei și folosite ca sursă de inspirație pentru analiza datelor din domeniul economic. Exemple în acest sens sunt economistul francez Antoine Augustin Cournot (1801-1877) și economistul englez William Stanley Jevons (1835- 1882), care au făcut în mod explicit apel la metode de observare a seriilor de timp preluate din astronomie sau meteorologie. Mai târziu, la începutul sec. XX, analiza seriilor de timp s-a dezvoltat ca un domeniu de cercetare specific științelor economice. În prezent, metodele de previziune bazate pe analiza seriilor de timp sunt foarte frecvent folosite datorită simplității lor, fiind implementate în majoritatea pachetelor software de previziune.


Seriile de timp pot fi *clasificate* după mai multe criterii, unul dintre cele mai relevante fiind stabilitatea evoluției în timp. După acest criteriu, putem avea serii de timp *staționare* și *non-staționare*, așa cum se poate observa în Fig.1.



(a) Serie de timp staționară în medie și varianță



(b) Serie de timp non-staționară în medie



(c) Serie de timp staționară în medie dar non-staționară în varianță

Fig. 1. Staționaritatea seriilor de timp

Staționaritatea poate fi apreciată din mai multe puncte de vedere.

Stationaritatea în medie presupune ca fenomenul observat să aibă aproximativ aceeași medie pe subintervale, ceea ce implică inexistența unui trend crescător sau descrescător. Astfel de evoluții se mai numesc și evoluții orizontale.

Stationaritatea în varianță presupune ca seria de timp observată să aibă o deviație față de medie aproximativ constantă pe subintervale.

Înainte de aplicarea unei metode de modelare și ulterior de predicție, seriile de timp sunt supuse în general unei proceduri de *prelucrare preliminară (ajustare)*. Rolul prelucrării preliminare este multiplu și vizează următoarele aspecte:

- În situația în care o serie de timp este nestationară, de multe ori se aplică proceduri pentru a o *staționariza*. Printre aceste proceduri se numără: calcularea diferențelor de ordinul întâi, calcularea indicelui de creștere, logaritmarea, **transformări de tip Box-Cox** ($y_t = \frac{x_t^\alpha - 1}{\alpha}$, $\alpha \neq 0$).
- Atunci când datele prezintă fluctuații sezoniere, iar obiectivul urmărit este observarea tendinței pe termen lung sau a fluctuațiilor ciclice, se recurge deseori la înlăturarea fluctuațiilor sezoniere. Aceasta procedură poartă denumirea de *desezonalizare*.
- Ajustarea seriilor de timp mai poate presupune *înlăturarea valorilor aberante* (valori foarte mari sau foarte mici datorate în special erorilor de înregistrare), *interpolarea* (estimarea valorilor istorice care lipsesc) etc.
- O practică des întâlnită în cazul datelor lunare este *înlăturarea efectului numărului de zile lucrătoare* dintr-o lună. De exemplu, dacă o lună are mai puține zile lucrătoare decât luna anterioară nu înseamnă că nivelul vânzărilor pentru un anumit produs a scăzut, ci trebuie comparat nivelul vânzărilor pe cele două luni, după ce este înlăturat efectul diferenței dintre numărul de zile lucrătoare pentru cele două luni.
- Atunci când datele sunt exprimate în prețuri curente, iar inflația este semnificativă, înainte de a aplica o metodă oarecare de extrapolare, se recurge la eliminarea inflației. Acest lucru se realizează prin transformarea seriei de timp în prețuri constante (comparabile) prin *inflatare* sau *deflatare*. Inflatarea are avantajul utilizării prețurilor celor mai actuale ca prețuri de referință. De exemplu se ia ca referință ultimul an și toate valorile sunt transformate în prețurile ultimului an.

Procese de tip “mers la întâmplare”

În anul 1900, Louis Jean-Baptiste Alphonse Bachelier, în teza sa *Teoria Speculației*, a fost prima persoană consemnată din istorie care a aproximat evoluția prețurilor pe bursele de valori cu o mișcare browniană sau, altfel spus, cu un “mers la întâmplare”. Matematicianul de origine franceză este considerat un pionier al matematicii financiare și al proceselor aleatoare.

Procesul de tip “mers la întâmplare” este un proces în care valoarea la momentul $t + 1$ este egală cu valoarea la momentul anterior plus o eroare:

$$y_{t+1} = y_t + e_t,$$

unde: e_t este o variabilă aleatoare normal distribuită de medie 0 și varianță constantă.




Fig. 2. Serie de timp reprezentând o variabilă aleatoare $N(0,1)$

Pentru că valorile au aceeași medie, 0, și aceeași varianță, 1, pe fiecare subinterval de timp, în graficul de mai sus avem un exemplu de serie staționară în medie și varianță.

Seria din Fig. 3 reprezintă un “mers la întâmplare” pur, în sensul ca datele au fost create artificial, în conformitate cu formula prezentată, fără să existe alți factori sau alte procese care să influențeze evoluția datelor. Din grafic se poate observa cu ușurință că procesul este în medie nestaționar.



Fig. 3. Proces de tip mers la întâmplare

În realitatea economică nu exista însă date care să reprezinte astfel de procese pure, ci date care pot fi approximate “grosso modo” cu astfel de procese. Să luăm ca exemplu evoluția zilnică a cursului valutar Ron/Euro în perioada ian.-sept. 2008 (Fig. 4).




Fig. 4. Evoluția cursului valutar Ron/Euro în perioada ian.-sept. 2008

Evoluția cursului valutar nu poate fi considerată un “mers la întâmplare” pur, aceasta fiind determinată de o serie de factori (factori care influențează raportul cerere-ofertă pentru o anumită valută) a căror influență nu o vom discuta aici dar care elimină caracterul pur aleator al procesului.

În cazul în care o serie de valori ar urma un de proces de tip “mers la întâmplare” pur, previziunea cea mai potrivită este ultima valoare înregistrată. Adică previziunea pentru momentul următor, $n+1$, este chiar valoarea din momentul n :

$$\hat{y}_{n+1} = y_n,$$

unde: \hat{y}_{n+1} - valoarea previzionată pentru momentul $t+1$;

y_n - valoarea reală înregistrată în momentul t .

Dacă însă procesul care stă la baza seriei de date nu este pur aleator, cum de altfel se întâmplă, este foarte probabil ca o altă metodă să fie mai potrivită.

Metodele de descompunere a seriilor de timp

Metodele de descompunere se întemeiază pe ipoteza ca valorile reale a unei serii de date statistice pot fi descompuse în următoarele categorii de variații sau mișcări.

- *Variație de lungă durată*, stabilă, numită și tendința. Această variație determină sensul general al evoluției procesului sau fenomenului evidențiat de seria de date statistice, marcând direcția fundamentală a mișcării.
- *Variații periodice, sezoniere sau ritmice în jurul tendinței*. Aceste variații au loc în anumite condiții specifice, fiind rezultatul acțiunii unor factori naturali (încasările în turism, producția în construcții, exportul unor produse agricole etc.).
- *Variații întâmplătoare, accidentale, perturbatoare sau reziduale*. Aceste variații sunt determinate de abaterile de la tendința și variațiile periodice, fiind rezultatul acțiunii unor factori imprevizibil, necuantificabili, de regulă de scurtă durată.

Nu orice serie statistică conține toate aceste tipuri de variații. De exemplu, sunt numeroase cazuri în care variațiile sezoniere pot să lipsească din seria de date statistice.

Folosirea seriilor statistice în previziune, impune asocierea celor trei componente după unul din cele două modele fundamentale: modelul aditiv sau modelul multiplicativ.

Modelul aditiv se utilizează în cazul unei relații de independență totală a fiecărei componente față de celelalte, rezultând din simpla însumare a acestora.

$$Y = T + S + E,$$

unde:

Y - variabila rezultativă;

T - tendința;

S - variații sezoniere;

E - variații întâmplătoare.

Modelul multiplicativ presupune existența unei relații de proporționalitate a componentelor seriei de date, valorile observate fiind produsul acestor componente.

$$Y = T \times S \times E$$

Evoluția unei serii statistice de timp cu sezonaliitate aditivă, respectiv multiplicativă, se prezintă în Fig. 10.




Fig.4. Tipuri de variație sezonieră

Etapile realizării unei previziuni prin metoda clasică de descompunere:

1. Se calculează o *medie mobilă de ordin k*. În general se utilizează ordinul 4 pentru date trimestriale, ordinul 12 pentru date lunare, 5 sau 7 pentru date zilnice etc. Dacă ordinul este par, se

aplică apoi o medie mobilă de ordin 2 pentru centrarea mediei mobile. Aceasta medie are rolul de a nivela fluctuațiile sezoniere, reprezentând o estimare provizorie a componentei de trend.

2. Se face diferența/raportul dintre *valorile observate și valorile obținute prin media mobilă centrată* obținându-se coeficienții de sezonalitate.

3. Se calculează *componenta sezonieră*, S_t , ca o medie aritmetică/geometrică a valorilor obținute în etapa anterioară pentru fiecare unitate de timp care formează ciclul sezonier (daca datele sunt lunare este calculata o medie pentru fiecare luna). Cu alte cuvinte, componenta sezonieră este reprezentată de coeficienții de sezonalitate medii.

4. Prin diferența/raportul dintre valorile observate si componenta sezoniera se obține *seria de timp desezonalizată* (Y-S).

5. Se estimează *componenta de trend*, T_t , printr-o metodă specifică acestei componente (funcții de tendință, spor mediu etc.) pornind de la *seria desezonalizată*.

6. Prin diferența/raportul dintre datele inițiale observate și suma/produsul componentelor de sezonalitate și trend se obține *componenta aleatoare*, E_t .

7. Se extrapolează componenta de trend și cea sezonieră pe perioada aferentă orizontului de previziune.

8. Se recompun valorile previzionate prin adunare/înmulțire.

Analiza seriilor de timp presupune

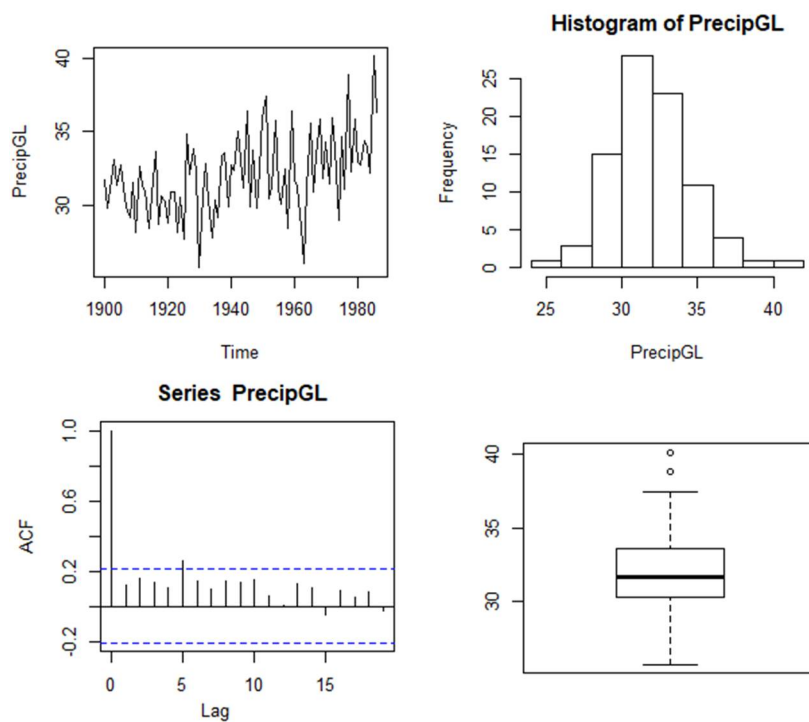
1. Analiza grafica

- Plot - a se vedea evolutia
- histograma – a se vedea asimetria
- boxplot – a se determina valorile aberante si teste din package **outliers**
- functia de autocorelatie

2. Teste statistice

- Homoscedasticitatea: testul Bartlett – Bartlett.test (se construiește în indice CO care are câte 29 de 1, 2 și 3 și se aplică testul pt $x = \text{PrecipGL}$ și $y = \text{CO}$)
- Testare ipotezelor legate de existența trendului – testul Mann-Kendall
<https://cran.r-project.org/web/packages/Kendall/Kendall.pdf>
<https://cran.r-project.org/web/packages/trend/trend.pdf>
- a. ipoteza nulă este că nu există trend monoton al seriei, iar cea alternativă este că există un astfel de trend

```
library(Kendall)
data(PrecipGL)
par(mfrow=c(2,2))
plot(PrecipGL)
hist(PrecipGL)
acf(PrecipGL)
boxplot(PrecipGL)
```



`MannKendall(PrecipGL)`

$\tau = 0.265$, 2-sided $p\text{-value} = 0.00029206$ # trend monoton


b. exista si varianta sezoniera a acest test:

`SeasonalMannKendall(PrecipGL)`

$\tau = 0.265$, 2-sided $p\text{-value} = 0.00028797$ # trend sezonier monoton

```
library(boot)
data(manaus)
manaus
SeasonalMannKendall(manaus)
```

$\tau = 0.0877$, 2-sided $p\text{-value} = 2.2559e-05$



Alternativ:

```
library(trend)
mk.test(manaus)
```

Mann-Kendall trend test

```

data: manaus
z = 4.3756, n = 1080, p-value = 1.211e-05
alternative hypothesis: true S is not equal to 0
sample estimates:
      S              varS              tau
5.180400e+04  1.401620e+08  8.891681e-02

```

c. Determinarea tendintei liniare prin metoda neparametrica a lui **Sen – library trend**

This test computes both the slope (i.e. linear rate of change) and confidence levels according to Sen's method. First, a set of linear slopes is calculated as follows:

$$d_k = \frac{x_j - x_i}{j - i}$$

for $(1 \leq i < j \leq n)$, where d is the slope, x denotes the variable, n is the number of data, and i, j are indices.

Sen's slope is then calculated as the median from all slopes: $b_{Sen} = \text{median}(d_k)$.

This function also computes the upper and lower confidence limits for sens slope.

```
library(trend)
```

```
sens.slope(PrecipGL)
```

Sen's slope

```

data: PrecipGL
z = 3.6222, n = 87, p-value = 0.0002921
alternative hypothesis: true z is not equal to 0
95 percent confidence interval: [0.01952381, 0.06217391]
sample estimates: Sen's slope: 0.04

```

```
sens.slope(manaus)
```

```

Sen's slope
data: manaus
z = 4.3756, n = 1080, p-value = 1.211e-05
alternative hypothesis: true z is not equal to 0
95 percent confidence interval: [0.0003428378, 0.0009065682]
sample estimates: Sen's slope: 0.0006241918

```

o Testarea stationaritatii

- in medie si tendinta – testul KPSS, in care ipoteza nula este stationaritatea in nivel (sau trend), iar cea alternativa este nestationaritatea in nivel (trend)

<https://cran.r-project.org/web/packages/tseries/tseries.pdf>

```
library(tseries)
```

```
kpss.test(x, null = c("Level", "Trend"), lshort = TRUE)
```

```
kpss.test(PrecipGL)
```

KPSS Test for Level Stationarity

data: PrecipGL

KPSS Level = 1.1118, Truncation lag parameter = 3, p-value = 0.01

Warning message: In kpss.test(PrecipGL) : p-value smaller than printed p-value

`kpss.test(PrecipGL, null = c("Trend"))`

KPSS Test for Trend Stationarity

data: PrecipGL

KPSS Trend = 0.091423, Truncation lag parameter = 3, p-value = 0.1

Warning message:

In kpss.test(PrecipGL, null = c("Trend")) : p-value greater than printed p-value

stationaritate in trend si nestationaritate in nivel

- testul Dickey-Fuller si ADF (Augmented Dickey-Fuller), in care ipoteza nula este existent unei unitati, iar cea alternative este stationaritatea

- o Determinarea punctelor de ruptura – Testele Pettitt, Buishand U Test, Hubert – in package **trend**.